유전자 변이로 암종을 읽는 AI

치료 분기의 첫 단계

환자 한 명의 유전자 4,384 개에 적힌 변이 표기만으로 26 개 암 아형을 분류합니다 .
점수보다 , 왜 그 점수인지를 보여 드립니다 .

0.4598

최종 Public 리더보드 Macro F1

암파서블 : 엄태은 (팀장) · 김민준 · 신혜원 · 이명석

Presentation Map

01 협업

GitHub · 디스코드 · 팀 가이드

02 데이터

6,201 명 · 4,384 유전자 · 26 아형

03 난점 · EDA

희소 · 불균형 · 라벨 충돌

04 선행 연구

점 돌연변이의 천장

05 전처리 · 파생변수

실험으로 검증

06 모델 · 검증

트리 + 텍스트 · Fold-safe

07 결과 · 해석

격차 추적 → 0.4598

08 치료 연결 · 결론

아형 → 치료 분기

매일 기록 , 브랜치 → PR → 리뷰로 통합

① 계획

팀 가이드

규정 · 데이터 한계 · 논문 10 편 · 진행 일지를 한 페이지에

② 개발

GitHub 브랜치

feat/ 이름 - 주제 → PR → 리뷰 → main. 리뷰에서 규정 위반 2 곳 수정

③ 검증

같은 5-fold

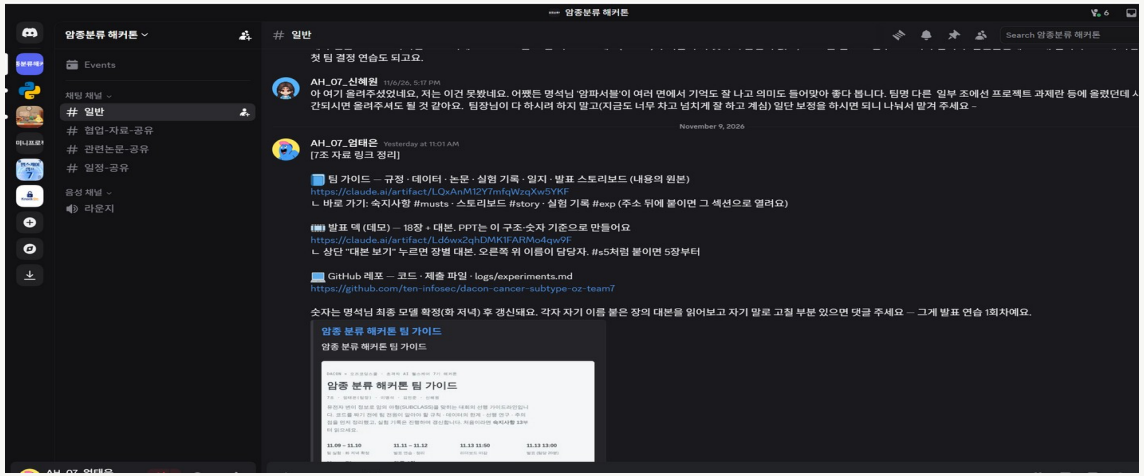
StratifiedGroupKFold · SEED 42 — 같은 시험지로 비교

④ 기록

experiments.md

실험 ID · CV · 리더보드 · 해석 — 기각된 실험도 기록





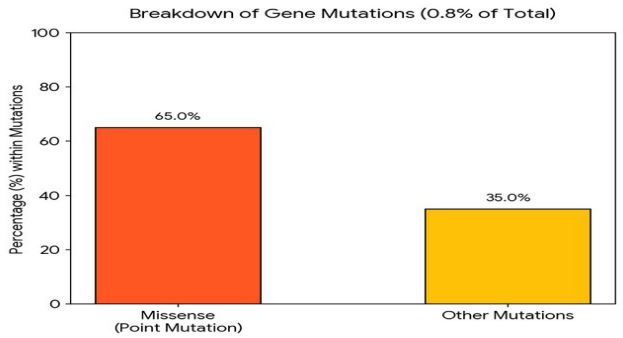
6,201 명의 유전자 변이로 26 개 암종을 판별

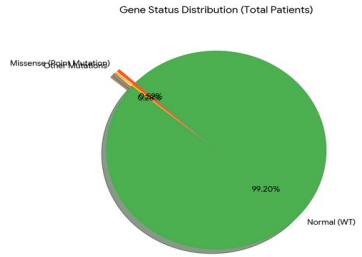
6,201
train 환자 수 · test 2,546

4,384
유전자 열 (WT 또는 변이 표기)

26
암 아형 — TCGA 코호트 약어

Macro F1
아형별 F1 의 단순 평균 — 소수 아형도 같은 비중





SNV = 하나의 염기 치환 (한 글자 변이)
- 미스센스 — 아미노산 변경 (예 : R273H) · 우리 데이터의 약 65%
- 논센스 — 단백질 절단 (예 : R213*)
- 침묵 (동의) — 아미노산 유지 (예 : R895R)

칸 하나를 읽는 법

TP53 열의 값 R273H

R 원래 아미노산 (아르기닌)
273 단백질에서 몇 번째 자리
H 바뀐 아미노산 (히스티딘) → 미스센스

R895R 침묵 · R213* 정지 · L1854fs 프레임시프트 · WT 정상 (99.2%)

현 프로젝트 데이터의 한계 : 선행 연구의 85–91% 는 CNV· 전장 정보 데이터를 포함한 조건에서 나와 수치 높음

— 발현량 · 복제수 변이 (CNV) · 염기서열 문맥 · 임상 정보
— KRAS · NRAS · TERT · GTF2I 등 핵심 유전자 일부
— **→ 입력 모달리티가 원천적으로 달라 직접 비교 불가**

SNV 는 하나의 염기가 다른 염기로 바뀐 변이입니다 . 85~91% 의 근거 : Soh 88.4%(+CNV) · CPEM 84.1%(+CNV) · Jiao 91%(전장) — 모두 CNV· 전장 포함 조건 . 우리 데이터 (하나의 염기 치환만) 와는 입력 모달리티가 달라 직접 비교 불가 .

모델 설계는 세 가지 데이터 난점에서 출발

SPARSITY

0.8%

27,185,184 칸 중 변이가 적힌 비율 . 변이 문자열 118,846 종은 거의 전부 한 번씩 → 0/1 + 요약 특성

IMBALANCE

20.7×

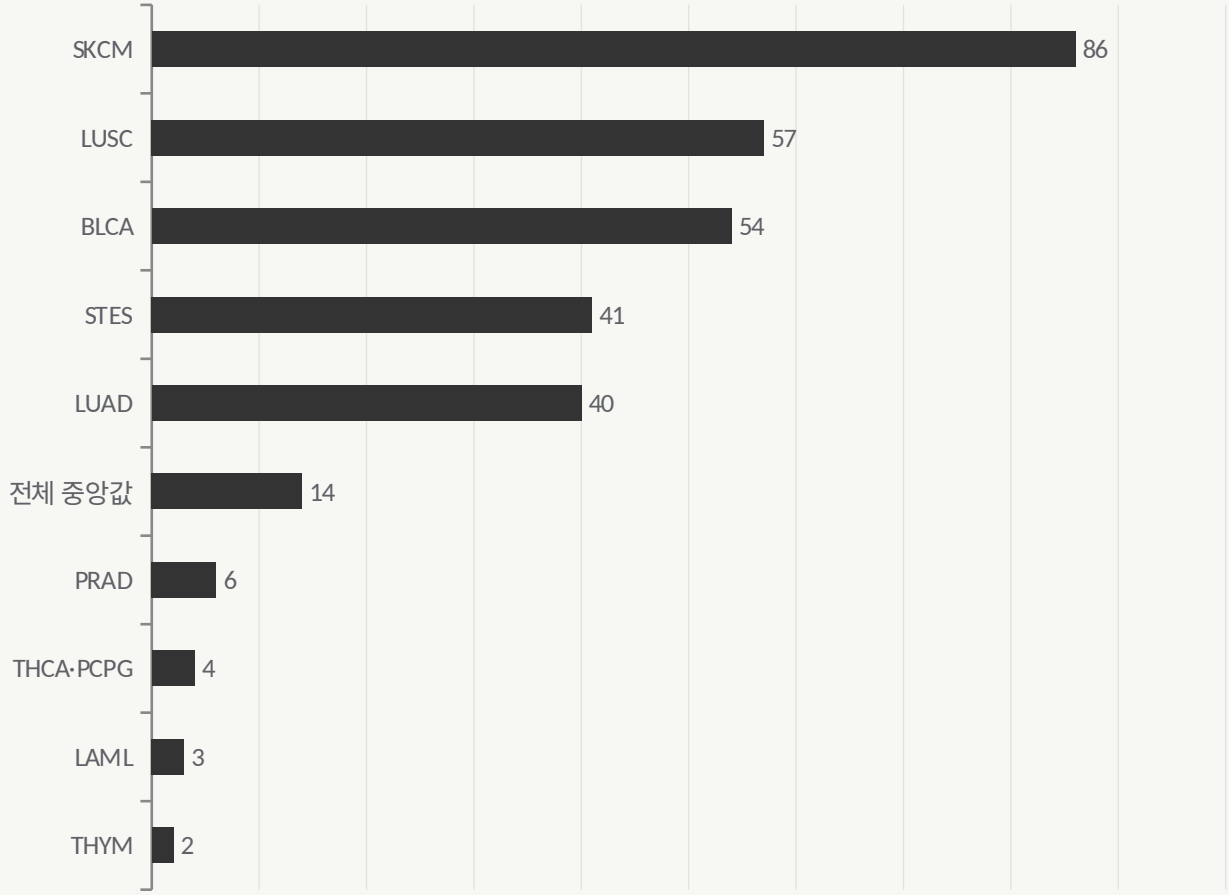
BRCA 786 명 vs DLBC 38 명 . Macro F1 은 아형마다 같은 비중 → 클래스 가중치

CONFLICT

445 쌍

같은 변이 프로필 , 다른 라벨 (KIPAN ↔ KIRC 272 · GBMLGG ↔ LGG 173) — 구조적으로 못 맞힘 → 그룹 CV. 이 구조가 뒤에서 점수 도약의 열쇠가 됩니다

변이 수로 추정 가능한 암종



원인이 보인다

자외선 (SKCM) · 흡연 (LUSC·BLCA·LUAD) 은 변이가 많고 , 혈액암 · 내분비암은 적다

긴 꼬리

최대 2,393 개 · 100 개 이상 391 명 (MSI·POLE) · 변이 0 개 94 명 (단서 없음)

모델로 연결

n_mut 한 열로 CV +0.04 (0.338 → 0.380) — 가장 싼 개선

선행 연구 : 점 돌연변이 단독으로 달성 가능한 성능 50~67% — 우리는 26 종에서 49%

1. 하나의 염기 치환 (SNV) 만 쓴 조건 — 우리와 직접 비교 가능

논문	입력	결과
Soh 2017	변이만	49.4%
DeepGene / mClass	12 개 암종	65.5 / 67.5%
TumorTracer 2015	변이	66.6% (외부 46%)
우리 (7 조)	**26 개 암종**	**49% · F1 0.49**

→ 하나의 염기 치환만으로 가능한 범위 : 대략 47~67%

2. 다른 모달리티 추가 — 직접 비교 불가 , 참고용

논문	추가 정보	결과
Soh 2017 (+CNV)	CNV	88.4%
CPEM 2019	변이율 ·CNV	84.1%
Jiao 2020 (전장)	전장 유전체	91%
OncoNPC 2023	패널 + 임상	F1 0.78 (≥0.9 → 0.94)

→ CNV· 임상 추가 시 84~91% (우리 데이터엔 없음)

---

3. 우리 프로젝트가 ' 제한된 정보 ' 라는 한계로 오히려 갖는 의미

① 우리 데이터에 실제로 없는 것

RNA 발현량 · 복제수 변이 (CNV) · 염기서열 문맥 · 임상 정보 (생존 · 치료 이력) · KRAS·NRAS·TERT·GTF2I 등 핵심 유전자

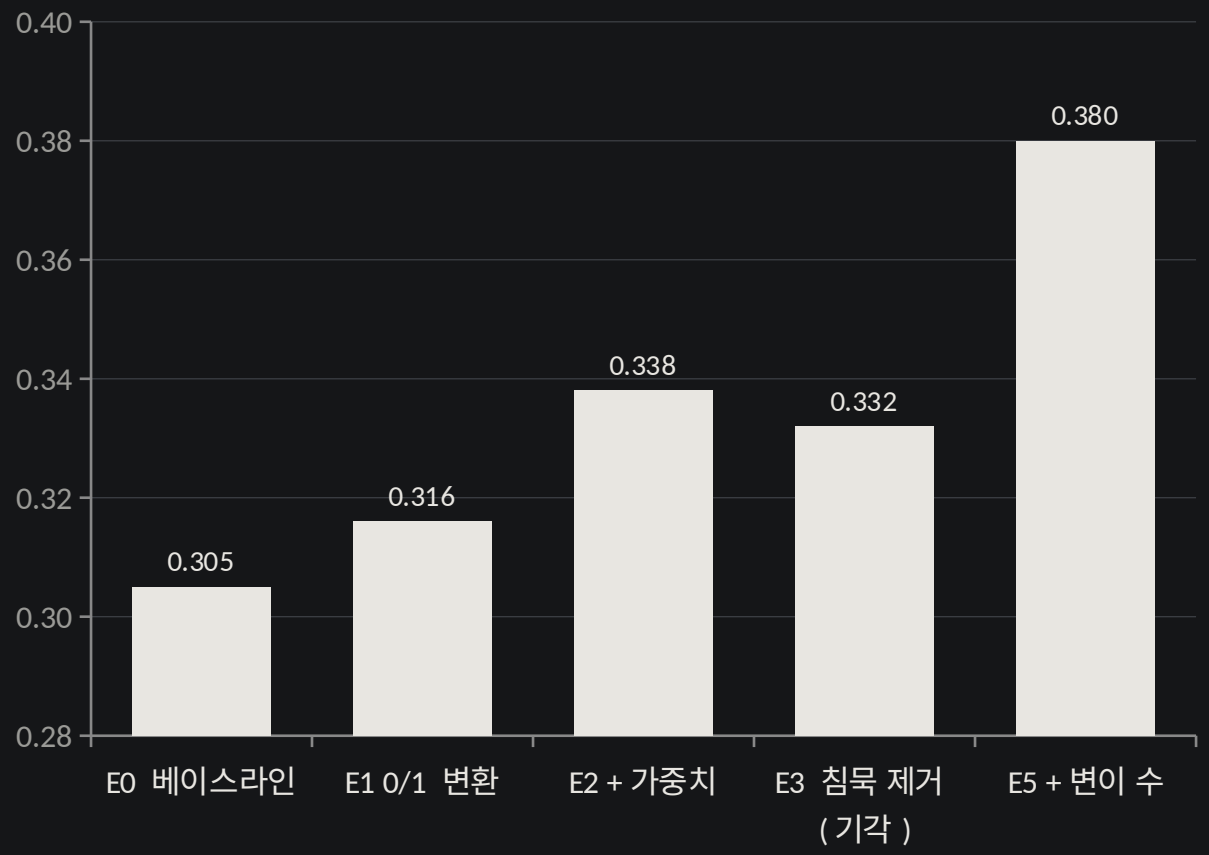
② 그래서 우리가 증명한 것

' 정보가 제한된 조건에서 어디까지 가능한가 ' — SNV 단독으로 26 개 암종 분류의 현실적 범위를 제시

③ 임상적 의미

검사 비용 · 시간이 큰 2 차 오믹스 (RNA·CNV) 없이 , 1 차 패널만으로 암종 후보를 좁히는 안전망을 구현

전처리 : 파싱 · 정규화 · 결측 처리의 핵심



— P1 문자열 → 0/1: 118,846 종 번호 매기기는 의미 없는 순서 (+0.011)

— P5 클래스 가중치 : 38 명 DLBC 도 786 명 BRCA 와 같은 비중 (+0.022)

— P3 침묵 변이 제거 → 기각 (−0.006): 승객 변이에도 신호 (Jiao 2020)

— **P4 환자당 변이 수 한 열 (+0.042) — 가장 싼 개선**

— P0 test 빈칸 237 개 → WT: 형식 처리일 뿐 , 분포는 보지 않음

파생변수 : 논문 아이디어를 실험으로 검증 — 0.380 → 0.450

특성	근거	CV 변화	판정
변이 유형별 개수 · 비율 (침묵 · 미스센스 · 정지 ·fs)	CPEM 변이율	**+0.024**	**채택 — 최대 단일 상승**
아미노산 치환 12 패턴 + 6 그룹 전이 72 열	TumorTracer 근사	+0.009 / +0.020	채택
드라이버 157 유전자 2 채널 (314 열)	Vogelstein 20/20	+0.012	채택 → LB 과적합 확인
신호경로 10 개 변이 부담 (20 열)	Sanchez-Vega 2018	+0.004	안정성용
아형별 임계값 보정	—	−0.008	기각 (중첩 검증)
중복 토큰 수 · 계층 후처리	데이터 관찰	+0.001 · −0.005	기각

유전자 열 없이 요약 특성 407 열만으로 CV 0.404 — 점수의 대부분은 환자 단위 요약에서 나온다

변이 문자열의 텍스트 표현 (토큰화 · TF-IDF · LinearSVC)

한 칸 → 토큰 : BRAF 열의 값 V600E

— gene_BRAF — 어느 유전자가 고장났나

— mut_V600E — 정확히 어떤 변이인가

— event_BRAF_V600E — 조합

— 환자 한 명 = 문서 한 장 → TF-IDF → LinearSVC (어휘는 fold 안 train 에서만)

왜 두 표현인가

트리 = 숫자의 비선형 조합 · 텍스트 = 문자열 규칙 . 서로 다른 실수 → 섞으면 상쇄

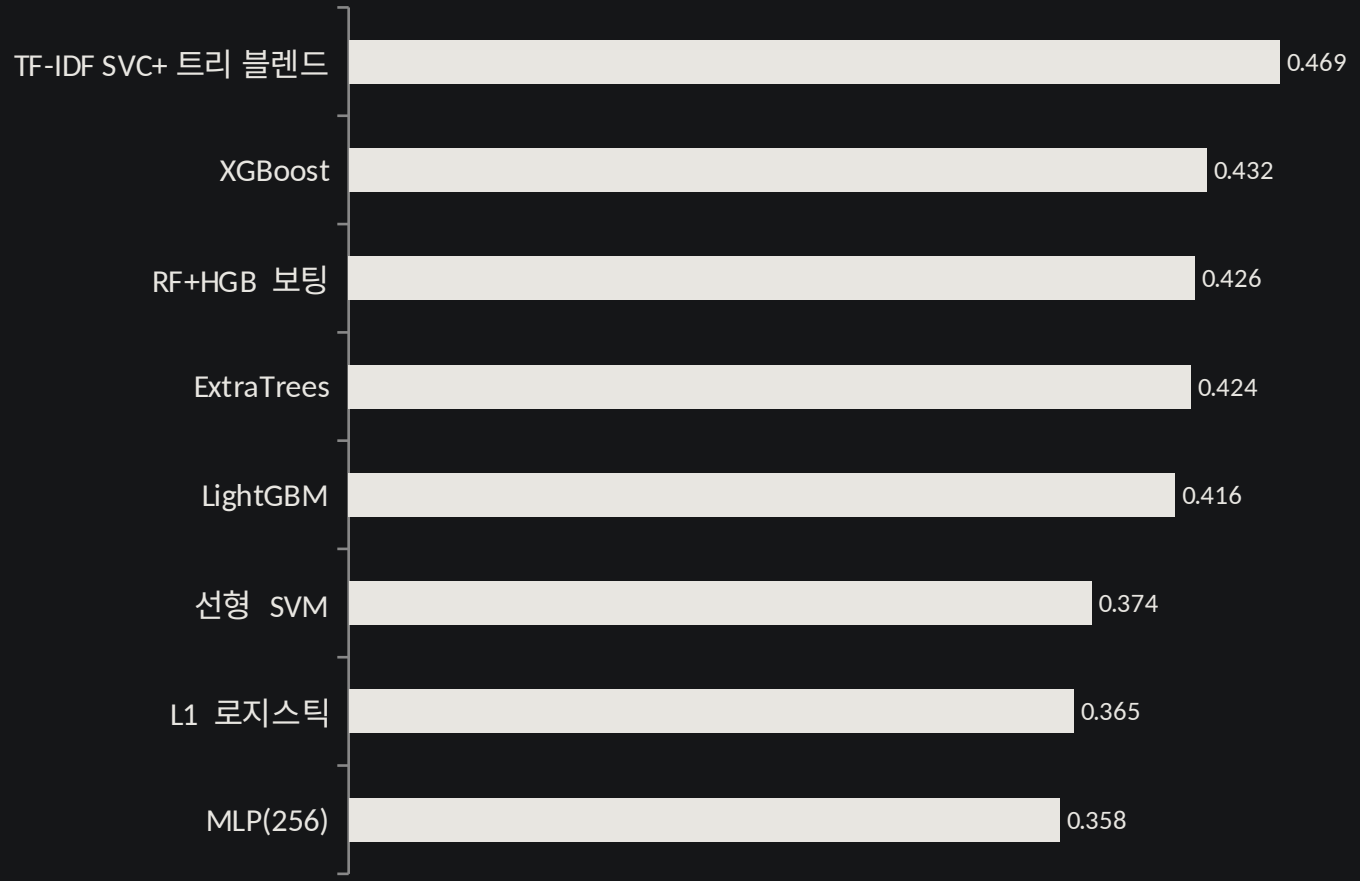
검증

치환 20×20 + 6 그룹 특성 리더보드 0.354 (단일 최고) · 텍스트와 블렌드는 다음 장

기각

5 층 토큰 ·char 3–5gram: OOF 0.475 → LB 0.350. 세밀할수록 train 을 외운다

동일 5-fold OOF 조건에서 8 종 모델 성능 비교



— 트리 계열 0.42~0.43 몰림 — 튜닝 (RandomizedSearch) 은 − 0.018 로 효과 없음

— 모델 종류보다 특성이 점수를 만든다

— 최종 : 트리 9 개 + 텍스트 SVM 에 kNN 15% · 변이 토큰 kNN 10% · 나이브 베이즈 3%

— LightGBM· 로지스틱도 시험 — 트리 · 선형과 겹쳐 블렌드 효과 없음 → 제외

— GPU 없음 · Colab CPU 에서 전부 재현 가능

데이터 누수 (Data Leakage) 방지를 위한 4 대 원칙

GROUP

프로필 단위 분할

같은 변이 프로필 (445 쌍) 은 같은 fold 에 — 외워서 맞히는 부풀림 차단

STRATIFIED

아형 비율 유지

26 개 아형 불균형을 fold 마다 같게 · DLBC 는 fold 당 7 명

FIT IN FOLD

fold 안 train 만 fit

유전자 필터 · TF-IDF 어휘 · 메타 모델 전부 . 리뷰로 train+test fit 2 곳 수정

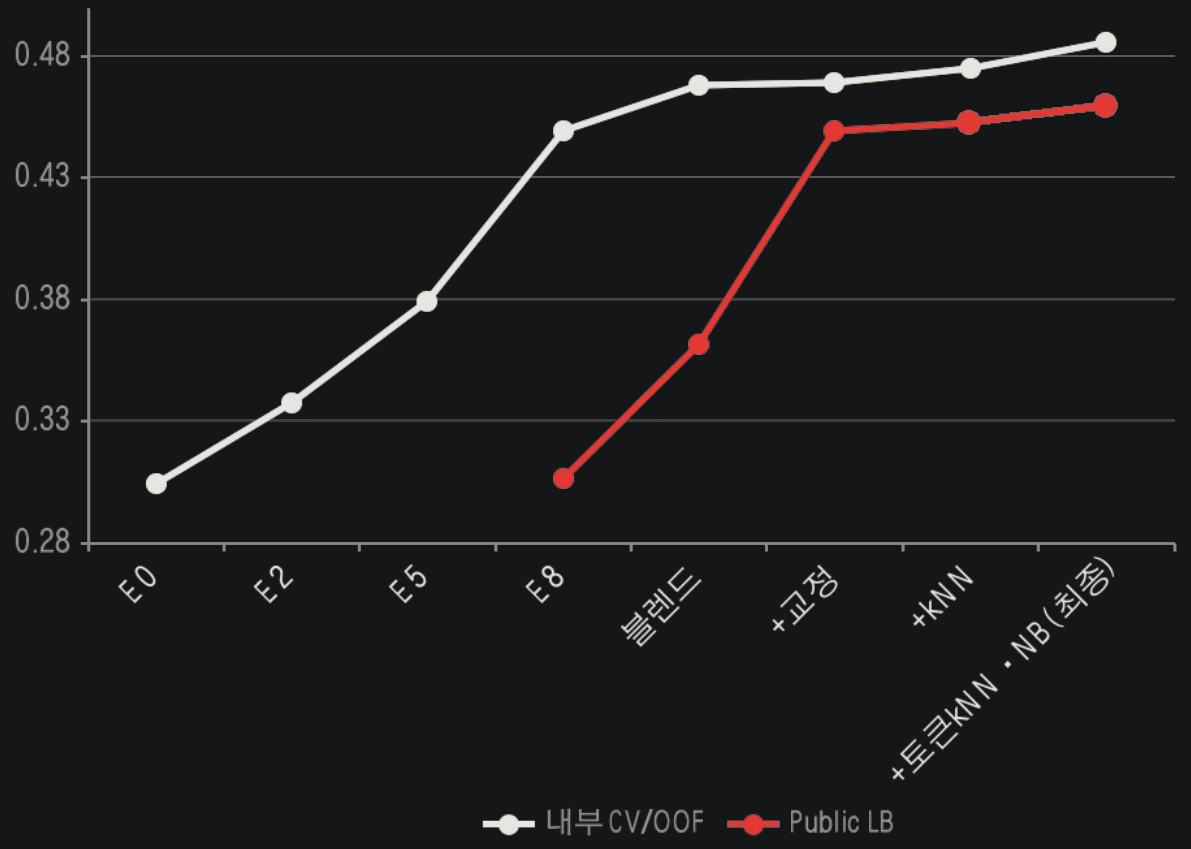
TEST

transform 만

분포 · 통계 보지 않음 · 빈칸 237 개는 형식 처리 (WT) 만

모든 실험 = 같은 분할 · SEED 42 — 팀원 간 점수를 비교하려면 시험지가 같아야 합니다

내부 0.486 · 리더보드 0.4598



0.4598

최종 Public 리더보드 Macro F1 · 규정 준수

+0.086

형제 라벨 교정 한 번의 상승 (전체 최대)

0.345 → 0.4598

격차 추적이 만든 상승

격차를 추적했더니 데이터 구조가 보였습니다 — 0.345 → 0.4598

1 **공통 격차 – 0.1**

모든 팀원 모델이 CV 보다 0.08~0.14 낮다 → 공통 원인은 test 분포 차이

2 **가설 A 설정 → 기각**

같은 특성 + 규제 설정 제출 → 0.305 변화 없음

3 **가설 B 특성 → 확정**

거친 특성 0.345~0.354 vs 세밀한 특성 0.305~0.319 — 세밀할수록 train 을 외운다

4 **다른 표현 섞기**

트리 (숫자) 0.6 + 텍스트 (문자열) 0.4 블렌드 → 0.362

5 **구조의 발견 +0.086**

test 266 명이 train 과 프로필 일치 . train 내 동일 프로필 422 그룹 전부 ' 같은 환자 , 다른 코호트 라벨 ' → 형제 라벨로 222 명 교정 → 0.448

6 **전담 분류기 +0.002**

혼동쌍 전담 분류기 (LUAD ↔ LUSC·HNSC ↔ LUSC, OOF 검증 채택) → 0.4501

7 **닮은 환자의 투표 +0.010**

kNN(닮은 유전자) · 토큰 kNN(정확히 같은 변이) · 나이브 베이즈 — 트리 · 텍스트와 다른 실수 → 0.4598

8 **규정 점검 → 제외**

쌍둥이 규칙 (test 행끼리 비교) 이 LB +0.010 을 냈지만 Data Leakage 규정 소지 → 최종 제출에서 뺌

하루 4 회 제출 = ' 점수 내기 ' 가 아니라 가설을 가르는 실험 — 그 추적이 0.345 를 0.4598 로 만들었습니다 — 점수보다 규정

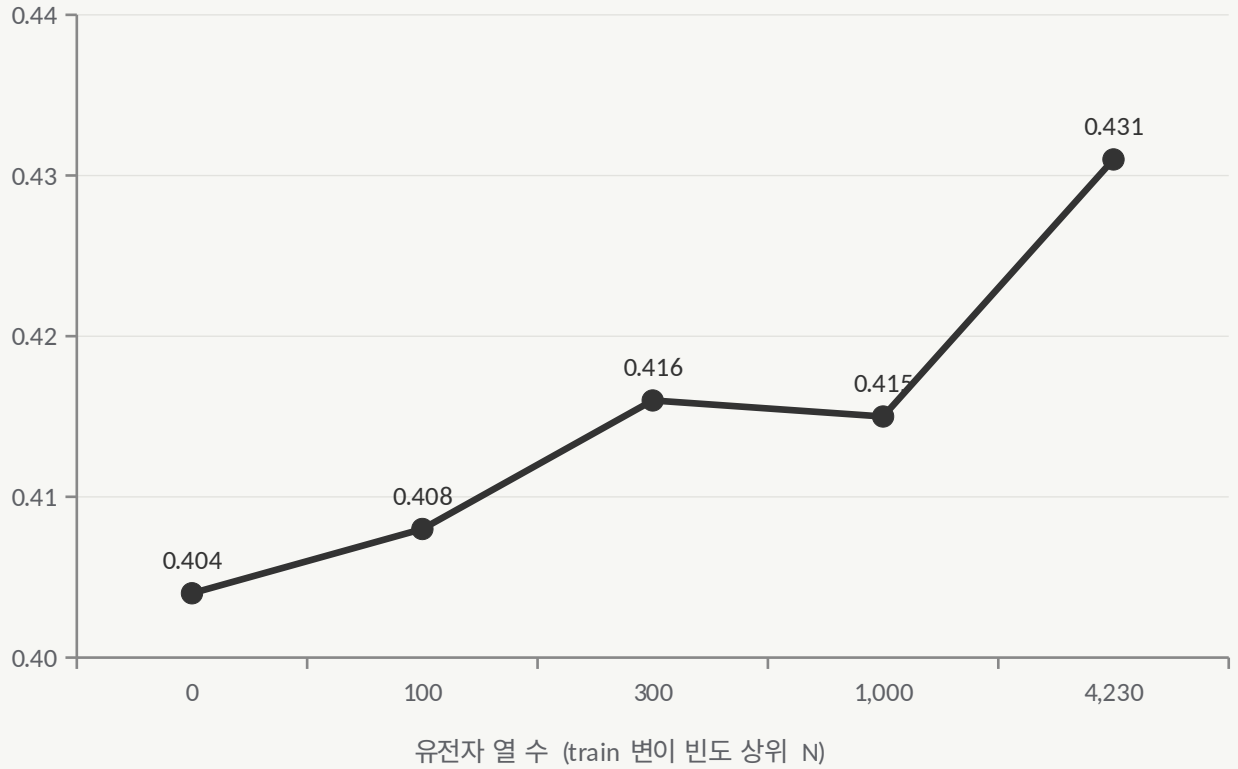
예측 성능이 낮은 암종은 모델이 아니라 데이터의 한계



아형	F1	이유
SARC	**0.16**	복제수 변이 주도 — 점 돌연변이에 안 보임
PCPG	**0.27**	변이 중앙값 4 개 · 융합 주도
THYM	**0.30**	30 명 변이 0 · GTF2I 누락
KIPAN	**0.32**	KIRC 와 라벨 중복 → test 에선 형제 교정으로 해결
HNSC	**0.35**	LUSC 와 흡연 공유 → 전담 분류기
PRAD	**0.37**	융합 (TMPRSS2-ERG)· 복제수 주도
잘 맞는 암	**0.69–0.88**	SKCM 0.88·COAD·ACC·THCA — 지문 유전자가 있는 암 . DLBC 는 0.46 회복

AI 알고리즘의 실패가 아니라 , 데이터 (SNV) 와 암의 생물학적 본질 (CNV· 융합) 사이의 도메인 미스매치

경량화 : 유전자 300 개면 충분 !



0.404

요약 특성만 (유전자 0)

점수의 대부분은 환자 단위 요약 407 열에서

0.416

상위 300 + 요약

열 1/6 · 학습 6 배 빠름 · 실제 병원 패널 규모

0.431

전체 4,230

+0.015 의 대가는 느린 학습과 과적합 위험

확신도 높은 환자부터 , 치료 분기의 첫 단계를 돕습니다

① 패널 결과
4,384 SNV

② 암종 예측
26 SUBCLASS

③ 확신도 게이트
P_max ≥ 0.9

④ OncoKB
Level 1/2

⑤ 의료진
MDT 판단

아형 (우리 라벨)	변이	근거	치료 분기
SKCM 흑색종	BRAF V600E	Level 1	BRAF+MEK 억제제 단독 — 승인 근거
COAD 대장암	BRAF V600E	Level 1	단독 실패 (EGFR 피드백) → EGFR 억제제 병용
BRCA 유방암	PIK3CA	Level 1	Alpelisib
GBMLGG 뇌교종	IDH1/2 · BRAF V600E	Level 1	Vorasidenib · Dabrafenib+Trametinib
BLCA 방광암	FGFR3	Level 1	Erdafitinib
KIPAN 유두상 (KIRP)	MET	임상시험	Cabozantinib (PAPMET)

CUP 코호트 · AI 일치 치료군

사망 위험

65%

감소

표적치료 기회 확대

2.2 배

이 데이터로는 ' 분자 아형 기반 맞춤 치료 ' 가 아니라 ' 암종 + 변이 기반 치료 후보 매핑 ' 까지만 가능합니다 . RNA·CNV· 융합이 없어 분자 아형은 판별 불가 . 61%→15% 연구도 RNA 기반이라 직접 예측 불가 .

천장 안쪽에 닿았고 , 왜 그 점수인지 압니다

0.305 → 0.486

Build — 전처리 + 파생변수 + 블렌드 , 기각 실험도 기록

0.4598

Reality check — 격차 추적 (특성→다양성→구조) 의 결과

6 / 26

Interpret — 26 개 중 약한 아형 6 개는 데이터의 한계로 설명

한계

— 라벨이 겹치는 445 쌍은 구조적으로 못 맞힘
— 복제수 · 발현 없이 SARC·PRAD·PAAD 는 어려움
— test 분포 차이로 CV 는 리더보드를 과대평가

다음 단계

— 확신도 기반 판정 보류 + 확률 보정
— 300 유전자 경량 모델로 서비스 시나리오 검증
— 복제수 변이가 있는 데이터로 외부 검증

만드는 것보다 ' 만든 것을 이해하고 설명하는 것 ' — 감사합니다 · github.com/ten-infosec/dacon-cancer-subtype-oz-team7